

AI Infra Sizing Assistant

고객 전달용 인프라 사전 산정 제안서

고객사	샘플 고객	프로젝트	사내 문서 RAG 구축
제안사	AI Infra Partner	기준일	2026-07-30
업무	Qwen 32B + Embedding + Reranker	목표	동시 요청 10 · TTFT p95 2초

3가지 구성안

구성안	GPU	동시 처리	3년 TCO	적용 판단
경제형	RTX 6000 Ada × 2	6	약 5,400만원	일부 대기 허용
권장형	H100 PCIe × 2	10	약 1억 6,000만원	SLA:30% 확장 여유
확장형	H200 SXM × 4	18	약 3억원	HA·향후 확장

권장 구성 근거

모델 상주 메모리, KV cache, 런타임 오버헤드, 동시 요청, 장애 여유 및 30% 성장분을 함께 반영했습니다. 가격은 계산 참고가이며 세금·마진·라이선스·설치·지원은 공급사 견적에서 확정해야 합니다.

기술 검토본

SLA와 아바타 파이프라인

지표	목표	예상	판정
TTFT p95	2.0초	1.72초	통과
ITL p95	80ms	48ms	통과
큐 대기 p95	0.5초	0.21초	통과
전체 p95	12초	8.84초	통과
STT→LLM→TTS→립싱크	3.5초 / 24FPS	2.78초 / 30FPS	실시간 가능

자동 생성 구성도



근거·위험·PoC

항목	근거	표본	예상 오차	필수 검증
GPU 사양	공식 사양	n=1	±2%	최종 SKU
VRAM	계산 추정	n=0	±20%	동일 모델·정밀도
처리량	외부 실측	n=2	±25%	성능/부하 분리
아바타 지연	계산 추정	n=0	±40%	단계별 지연·FPS
가격	계산 참고가	n=0	±30%	공급사 유효 견적